

Aplicación de aprendizaje profundo en un modelo de dimensionamiento de lotes, con capacidad limitada y demanda estocástica en procesos de remanufactura

Alejandro Castro¹, Maria Paula Huezo², Luis Madrigal³, Ricardo Marin⁴, Alejandra Urtecho⁵

¹Universidad de Costa Rica, Carné: B61717

²Universidad de Costa Rica, Carné: B63517

³Universidad de Costa Rica, Carné: B64017

⁴Universidad de Costa Rica, Carné: B64093

⁵Universidad de Costa Rica, Carné: B67292

A problem of lot sizing with stochastic demand, multiple stages and unlimited capacity is analyzed, in which remanufacturing processes are addressed. This model has the objective of finding the optimum quantity of parts to the processor, minimizing the production cost. The main objective of this article is to know how capacity affects the model under study, for this reason, it proposes a capacity restriction for the variable number of parts to process. In addition, deep learning is used to predict the cost of production with both limited and unlimited capacity, thereby validating and comparing both models, where a percentage of prediction error is obtained for the limited and unlimited capacity model, from 0.56% and 5.58% respectively. The results show that through neural networks it is possible to identify the significant variables for each one of the models, of which it is found that capacity is an important factor to consider in the model when it is limited.

Se analiza un problema de dimensionamiento de lotes con demanda estocástica, etapas múltiples y capacidad ilimitada, en el cual se abordan procesos de remanufactura. Dicho modelo tiene el objetivo de encontrar el óptimo de cantidad de piezas a procesar, minimizando el costo de producción. El objetivo principal de este artículo es conocer cómo afecta la capacidad en el modelo bajo estudio, por esta razón, se propone una restricción de capacidad para la variable de cantidad de piezas a procesar. Además, se utiliza aprendizaje profundo para predecir el costo de producción tanto con capacidad limitada como ilimitada, con lo que se logra validar y comparar ambos modelos, donde se obtiene un porcentaje de error de predicción para el modelo de capacidad limitada como ilimitada, de 0,56% y 5,58% respectivamente. Se observa que por medio de las redes neuronales se logra identificar las variables significativas para cada uno de los modelos, de lo cual se comprueba que la capacidad es un factor importante por considerar en el modelo cuando es limitada.

Index Terms—Dimensionamiento de lotes, aprendizaje profundo, análisis de capacidad, remanufactura, Programación estocástica multietapa

I. INTRODUCCIÓN

La revolución de la industria 4.0 ha transformado el sector de manufactura conforme se ha dado una integración de nuevas tecnologías que han permitido reconfigurar los procesos de fabricación, modelos de negocio, gestión y análisis de las operaciones [1].

Actualmente, en la industria manufacturera, la planeación y control de la producción involucran la toma de decisiones que determinan costos de producción, capacidad para producir lo que el cliente demanda, compra de materia prima, eficiencia y balanceo de líneas con una asignación de carga de trabajo y productividad, para los cuales es fundamental contar con herramientas que permitan un adecuado análisis. [1].

Nace el interés de conseguir una herramienta que permita un conveniente análisis y gestión de información sobre capacidad. Gracias a la cuarta revolución industrial, existe la posibilidad de integrar el uso de redes neuronales artificiales para la predicción de variables y parámetros importantes en la estimación de costos, como lo es el costo total de producción en el caso de la presente investigación.

Dicho lo anterior, se procede a utilizar redes neuronales artificiales para predecir el costo total de producción de un

escenario de variables y parámetros que permitan analizar el tamaño de los lotes y capacidad en un contexto de industria con remanufactura. Los apartados de la investigación son los siguientes: en la sección II se contextualiza sobre estudios recientes acerca de dimensionamiento de lotes y casos de estudio que involucran redes neuronales artificiales. Posteriormente, en la sección III, se justifica la crítica en cuestión al tema de capacidad y en el IV se detalla el diseño; en la sección V se incluye la validación para la propuesta. Finalmente, en el apartado VI se encuentran los principales hallazgos y en la VII las futuras líneas de investigación.

II. ESTADO DEL ARTE

A. Dimensionamiento de Lotes

Las decisiones de dimensionamiento de lotes dan lugar al problema de identificar cuánto de un producto producir de tal manera que se minimicen los costos de instalación, producción y mantenimiento, y que a su vez satisfaga la demanda [2]. Dependiendo de la complejidad del modelo se pueden tomar en cuenta diferentes horizontes de planeación, número de niveles (un nivel implica un producto simple, niveles o etapas múltiples implican operaciones tales como montaje o

desmontaje de piezas), cantidad de productos, restricciones de capacidad, demanda determinística o estocástica, control de inventario, costos de alisto y otros.

Por ejemplo, en [3], [4] y [5], se desarrollan modelos con demanda determinística de dimensionamiento de lotes con etapas múltiples, utilizando variables tales como retrasos, pedidos pendientes, tiempos de espera y nivel de servicio. Por otra parte, en [6] y [7] se desarrollan modelos de dimensionamiento de lotes de dos niveles con demanda estocástica, en ellos se contemplan diferentes variables tales como el flujo de productos, costos de transporte, eficiencia de la fuerza laboral y otras. Además, en [8] y [9] se realizan modelos para productos y etapas múltiples, sin embargo, se diferencian en que para lograr encontrar la solución del problema se utiliza el algoritmo de relajación de Lagrange. En [10] se desarrolla un modelo de etapas múltiples, demanda estocástica para dimensionamiento de lotes, pero este contempla una capacidad limitada y es resuelto mediante un modelo de programación entera estocástica de etapas múltiples.

El interés principal de la investigación en curso corresponde a los modelos de dimensionamiento contemplando procesos de remanufactura. La remanufactura se refiere a un conjunto de operaciones de recuperación de valor agregado donde los componentes o productos usados y/o devueltos se restauran a una condición tan buena como nueva [11].

Entre algunas de las investigaciones recientes que contemplan dicho proceso, se encuentra [12], la cual muestra el desarrollo de un modelo de dimensionamiento de lotes, bajo una demanda estocástica, con un solo producto y dos niveles, donde se contemplan variables tales como el nivel de servicio y costos de producción. En [13] se muestra el modelo contemplando niveles múltiples y procesos de remanufactura, en donde su solución se basa en el modelo de programación entera estocástica de etapas múltiples, sin embargo, en estos no se consideran restricciones de capacidad para los procesos.

Por esta razón, nace el interés de conocer los modelos que contemplan una capacidad limitada. Para ello existe la clasificación CLSP, por sus siglas en inglés “Capacitated Lot-Sizing Problem”, el cuál corresponde a un problema de tamaño de lote económico con restricciones de capacidad para la producción, donde se muestra que tanto, la cantidad de productos procesados en el tiempo total de producción, como la cantidad de tiempo que se toma en alistar, tienen que ser menores o iguales a la capacidad establecida, para así determinar la cantidad a producir para satisfacer la demanda [14].

Dicho tipo de modelo ha sido utilizado en distintas investigaciones, variando el tipo de parámetros a tomar en cuenta, por ejemplo, en [15] se tiene un problema de dimensionamiento de lotes capacitados, donde se tiene un parámetro de capacidad disponible que restringe algunas variables, multiproducto y multinivel (MLCLSP), el cual considera recursos limitados y fases de tiempo.

También, en [16], se tiene el algoritmo de tiempo O(T3), el cual considera capacidad estacionaria y costos de inventario lineales, donde se agrega una variable “M” que determina el máximo de la demanda.

Asimismo, en [17] y [18] se aborda un problema de

máquinas paralelas y de dimensionamiento de lotes, considerando ciertas restricciones de capacidad, donde se denota un parámetro de producción de horas disponibles, el cual tiene que ser mayor a las horas de producción, además de múltiples elementos como tiempos de configuración, demanda estocástica y horizonte de tiempo largo, con el objetivo de satisfacer la demanda y maximizar la cantidad de producción.

Por otra parte, se encuentra un estudio del modelo SCLSP, el cual considera el problema de dimensionamiento de lotes capacitados, donde se tiene un parámetro de capacidad en el que se encuentran 3 niveles: bajo, medio y alto. Este es de ítems múltiples dinámicos estocásticos, considera un único recurso en un horizonte de planificación largo. En dicha investigación, se realiza un modelo con una solución heurística [19].

Además, en [20] se plantea el problema del tamaño de lote de desmontaje con ventas perdidas, dos niveles, múltiples productos y con limitantes de capacidad, este propone un algoritmo genético para su solución y un enfoque híbrido, entendiendo la planificación del desmontaje como la cantidad de productos al final de la vida útil.

A continuación, se muestra un resumen de los modelos descritos anteriormente, donde se logra comparar el modelo a desarrollar con respecto a los ya existentes.

Referencia	Niveles	D.T	D.E	C.L	C.I	R	U	P.M	V.P
[3]	M	x		x	x		x		
[4]	M	x					x		x
[5]	M	x			x			x	
[6]	T		x	x			x		
[7]	T		x	x				x	
[8]	M		x	x				x	
[9]	M		x		x			x	
[10]	M		x	x			x		
[12]	T		x	x		x	x		
[13]	M		x		x	x	x		x
[14]	M	x		x				x	
[15]	M		x	x				x	
[16]	T	x		x		x		x	
[17]	T		x	x				x	
[18]	M		x	x				x	
[19]	M		x	x				x	
[20]	T	x		x			x	x	x
Propuesta	M		x	x		x	x		x

TABLE I
RESUMEN DE REVISIÓN BIBLIOGRÁFICA DE MODELOS DE DIMENSIONAMIENTO DE LOTES

M: múltiples niveles, T: dos niveles, D.T: demanda determinística, D.E: demanda estocástica, C.L: capacidad limitada, C.I: capacidad ilimitada, R: remanufactura, U: un solo producto, P.M: productos múltiples, V.P: ventas perdidas

B. Redes Neuronales Artificiales

Como punto de partida, es importante tomar en cuenta una perspectiva conceptual que permita introducir las redes neuronales artificiales. Según [21] las redes neuronales artificiales (RNA) están conformadas por algoritmos del campo de la inteligencia artificial, que permiten modelar abstracciones complejas en datos, usando una arquitectura compuesta por una conexión de neuronas que transfieren información.

En [22] se explica el funcionamiento de las RNA, este se basa en el manejo y mecanismo biológico del sistema nervioso humano, el cual permite entrenar la red neuronal mediante aprendizaje supervisado o sin supervisar, para tareas específicas a través de grandes muestras de ejemplos. En cuanto a la aplicación del aprendizaje supervisado, en [23] se estudia la predicción de falla de equipo basada en análisis de redes neuronales, incorporando los parámetros registrados durante el procesamiento de las máquinas, los cuales alimentan el modelo, permitiendo la predicción del nivel de degradación del rendimiento operativo de generadores eléctricos.

Por otra parte, para la aplicación de la inteligencia artificial en programación estocástica multietapa, [24] plantea un estudio de problemas de múltiples etapas donde se contemplan los riesgos asociados al procesamiento de productos múltiples con una demanda estocástica. Además, se investiga la factibilidad de utilizar el aprendizaje supervisado como las redes neuronales y procesos estadísticos Gaussianos, así como la técnica de aproximación de los árboles con escenarios aleatorios generados con simulación Monte Carlo, para la identificación de mejores soluciones para la programación estocástica multietapa. El estudio logra abordar el caso desde un modelo de predicción de la mejor solución al problema, en vez de contemplar la complejidad de un modelo computacional que optimizara.

III. CRÍTICA TEÓRICA

A. Justificación

En el artículo [13], se contempla un problema de dimensionamiento de lotes y un proceso el cual contiene remanufacturado, es decir, la transformación de un producto usado o que ha sido devuelto en uno nuevo, pero en este caso solamente con un tipo de producto y en cada período se devuelve en cantidad limitada, donde están presentes tres subprocessos: desmontaje, restauración y reensamblaje.

El producto se desmonta en una determinada cantidad de partes y estas deben de ser clasificadas como recuperables y no recuperables, donde la función objetivo se basa en minimizar el costo de producción contemplando el costo fijo de instalación, costo de mantener el inventario, costo de venta perdida, costo de partes descartadas y costo de remanufacturar las piezas.

El objetivo es encontrar el óptimo de plan de producción, considerando la incertidumbre de la demanda, cantidad de devoluciones, calidad de devoluciones y costos de producción.

Debido a que los parámetros del modelo, tales como la demanda y los costos asociados al proceso, se consideran estocásticos, y que además se consideran etapas múltiples, hace que el modelo sea más aplicable a la realidad.

Sin embargo, este modelo asume una capacidad de producción ilimitada, lo cual no se apega a lo que sucede de manera recurrente en el campo laboral, por lo cual se propone considerar restricciones de capacidad para cada uno de los procesos mencionados, con el objetivo de que sea aplicable a la realidad, considerando la diferencia de costos de producción resultantes.

La propuesta es una restricción de capacidad para las variables “cantidad de piezas procesadas en proceso” limitando

la cantidad máxima de piezas a procesar en el proceso. Para ello se define la variable " C_p^n ", que corresponde a la capacidad máxima para el proceso p , sea este desmontaje, restauración o reensamblaje, en un determinado período de tiempo en un nodo en específico de la red.

Posteriormente, se utiliza el aprendizaje profundo para dar solución al problema, y lograr predecir el costo de producción para el modelo de dimensionamiento de lotes con remanufactura con capacidad limitada. También se da solución al problema con capacidad ilimitada con el fin de comparar los resultados obtenidos. Para ello se elabora una base de datos, contemplando todas las variables y parámetros que a su vez cumplen con las restricciones del artículo.

IV. DISEÑO

A. Formulación matemática del modelo de programación estocástica

Seguidamente se muestra el modelo de programación estocástica de [13] para problemas de dimensionamiento de lotes de múltiples niveles con remanufactura y ventas perdidas. Este modelo es utilizado para generar el conjunto de datos que alimentan las redes neuronales, de forma tal que estas logren obtener una predicción de costos totales a partir de unas determinadas variables de entrada, que respeten las restricciones y parámetros del modelo.

Este modelo utiliza períodos de tiempo discretos y las decisiones se pueden tomar progresivamente a medida que se recopila información sobre demanda, retornos y costos.

Para abordar este problema, se supone que el proceso de entrada estocástico tiene un espacio de probabilidad finito para que la información sobre la evolución de los parámetros inciertos pueda representarse mediante un árbol de escenarios discretos. Dicha estructura de información se puede representar como un árbol de escenarios (ν, ε) con niveles o etapas t . Una etapa t puede corresponder a uno o varios períodos de planificación. Cada nodo $n \in \nu$ corresponde a una sola etapa, t^n representa una posible realización de los parámetros inciertos en el período de tiempo. Cada nodo n tiene un único nodo predecesor denominado a^n . Un escenario se define como una ruta en el árbol desde el nodo raíz a un nodo hoja y representa un posible resultado de los parámetros de entrada estocásticos en todo el horizonte de planificación.

Se utilizan las siguientes anotaciones para la formulación del problema:

- ν^t : conjunto de nodos que pertenecen a la etapa t .
- $C(n)$: conjunto de hijos del nodo n .
- p^n : probabilidad asociada con el estado representado por el nodo n .
- p^{nm} : probabilidad de transición del nodo n a su nodo hijo m .
- I : número de tipos de partes involucradas en un producto.
- γ : conjunto de todos los productos involucrados en el sistema $\gamma = \{0, \dots, 2I + 1\}$, donde $i = 0$ corresponde a productos devueltos e $i = 2I + 1$ corresponde a los productos remanufacturados.
- γ_r : conjunto de piezas recuperables proporcionadas por el proceso de desmontaje, $\gamma_r = \{1, \dots, I\}$

- \mathcal{J}_s : conjunto de piezas reparables proporcionadas por los procesos de restauración
- \mathcal{J} : conjunto de procesos de producción, $\mathcal{J} = \{0, \dots, I+1\}$, donde $p = 0$ corresponde al proceso de desmontaje, $p = 1, \dots, I$ corresponde a los procesos de restauración y $p = I+1$ corresponde al proceso de reensamblaje.
- α_i : número de partes contenidas en un acabado. Es decir, sea un producto devuelto o remanufacturado, es determinista y no varía entre los nodos

Los parámetros estocásticos se introducen de la siguiente manera:

- r^n = Cantidad de productos devueltos recogidos en el nodo $n \in \nu$
- d^n = demanda en el nodo $n \in \nu$
- π_i^n = proporción de partes recuperables $i \in \mathcal{J}_r$ adquirido al desmontar una unidad de producto devuelto en el nodo $n \in \nu$
- l^n = costo de penalización por ventas perdidas en el nodo $n \in \nu$
- f_p^n = costo de configuración para el proceso $p \in \mathcal{J}$ en el nodo $n \in \nu$
- h_i^n = costo de inventario unitario por parte $i \in \mathcal{J}$ en el nodo $n \in \nu$
- q_i^n = costo unitario por descartar una parte recuperable o un producto devuelto $i \in \mathcal{J}_r \cup \{0\}$ en el nodo $n \in \nu$
- g^n = costo unitario por descartar las partes irrecuperables obtenidas al desmontar una unidad de producto devuelto en el nodo $n \in \nu$

Se asume que $l^n \gg g^n$ para todos los $n \in \nu$. Las variables de decisión involucradas en el modelo son:

- x_p^n : cantidad de piezas procesadas en proceso $p \in \mathcal{J}$ en el nodo $n \in \nu$
- $y_p^n \in \{0, 1\}$ variable de configuración para el proceso $p \in \mathcal{J}$ en el nodo $n \in \nu$
- s_i^n : nivel de inventario de la parte $i \in \mathcal{J}$ en el nodo $n \in \nu$
- w_i^n : cantidad de la parte i descartada $i \in \mathcal{J}_r \cup \{0\}$ descartado en el nodo $n \in \nu$
- ℓ^n : ventas perdidas de productos remanufacturados en el nodo $n \in \nu$

El modelo de programación lineal de enteros mixtos se proporciona a continuación.

$$\min \sum_{n \in \nu} \sum_{p \in \mathcal{J}} p^n (\sum f_p^n y_p^n + \sum_{i \in \mathcal{J}} h_i^n s_i^n + l^n \ell^n + \sum_{i \in \mathcal{J}_r \cup \{0\}} q_i^n w_i^n + g^n x_0^n) \quad (1)$$

Sujeto a:

$$x_p^n \leq d^n y_p^n, \forall p \in \mathcal{J}, \forall n \in \nu \quad (2)$$

$$s_0^n = s_i^{a^n} + r^n - x_0^n - w_0^n, \forall n \in \nu \quad (3)$$

$$s_i^n = s_i^{a^n} + \pi_i^n \alpha_i x_0^n - x_i^n - w_i^n, \forall i \in \mathcal{J}_r, \forall n \in \nu \quad (4)$$

$$s_i^n = s_i^{a^n} + x_{i-I}^n - \alpha_i x_{I+1}^n, \forall i \in \mathcal{J}_s, \forall n \in \nu \quad (5)$$

$$s_{2I+1}^n = s_{2I+1}^{a^n} + x_{I+1}^n - d^n + \ell^n, \forall n \in \nu \quad (6)$$

$$s_0^0 = r_0^0 - x_0^0 - w_0^0 \quad (7)$$

$$s_i^0 = \pi_i^0 \alpha_i x_0^0 - x_i^0 - w_i^0, \forall i \in \mathcal{J}_r \quad (8)$$

$$s_i^0 = x_{i-I}^0 - \alpha_{i-I} x_{I+1}^0, \forall i \in \mathcal{J}_s \quad (9)$$

$$s_{2I+1}^0 = x_{I+1}^0 - d^0 + \ell^0, \forall n \in \nu \quad (10)$$

$$s_i^n \geq 0, \forall i \in \mathcal{J}, \forall n \in \nu \quad (11)$$

$$\ell^n \geq 0, \forall n \in \nu \quad (12)$$

$$x_p^n \geq 0, \forall p \in \mathcal{J}, \forall n \in \nu \quad (13)$$

La función objetivo (1) minimiza el costo total esperado, en todos los nodos del árbol de escenarios. La restricción (2) enlaza las variables de cantidad de producción con las variables de configuración. Las restricciones (3) - (10) son las restricciones de balance de inventario, se asumen los inventarios iniciales con un valor de 0. Las restricciones (11) - (13) son de no negatividad.

B. Propuesta de restricción

Se propone una restricción de capacidad para las variables X_p^n , determinando la cantidad máxima de piezas a procesar en el proceso p , sea este desmontaje, restauración o reensamblaje. Para ello se define la variable " C_p^n ", que corresponde a la capacidad máxima para el proceso $p \in \mathcal{J}$ en el nodo $n \in \nu$. La restricción se muestra a continuación:

$$x_p^n \leq C_p^n, \forall p \in \mathcal{J}, \forall n \in \nu \quad (14)$$

V. VALIDACIÓN

A. Generación de instancias

Para la generación de los diferentes escenarios, se definieron 2 valores para los radios g/h , f/h y r/d , donde $g/h \in \{2, 4\}$, $f/h \in \{200, 400\}$ y $r/d \in \{1, 3\}$. Homólogamente, se definieron valores para las T etapas y K ramas, donde $T \in \{4, 5\}$ y $K = 2$, a partir de las instancias generadas. La longitud de cada etapa corresponde a cinco períodos y el número de partes contenidas en un producto $\alpha_i = 2$. Además, para dichas instancias, se tomaron como valores de referencia los definidos en [13], el costo de mantenimiento de inventario h^n en el nodo n es un número aleatorio que está distribuido uniformemente en el intervalo de $[0, 10]$; el costo de producción g^n es un número aleatorio que está distribuido uniformemente en el intervalo de $[0.8(g/h)\bar{h}, 1.2(g/h)\bar{h}]$, donde \bar{h} es el costo promedio de mantenimiento de inventario; el costo a alistar f^n es un número aleatorio que está distribuido uniformemente en el intervalo de $[0.8(f/h)\bar{h}, 1.2(f/h)\bar{h}]$; la demanda d^n está distribuida uniformemente en el intervalo de $[0, 100]$; r^n está distribuida uniformemente de forma aleatoria en el intervalo de $[0.8(r/d)D, 1.2(r/d)D]$ donde D es la demanda promedio y la proporción de partes recuperables π_i^n está distribuida uniformemente en el intervalo de $[0.4, 0.6]$. El costo de penalización por ventas perdidas l^n es de 10 000 por unidad y la probabilidad de ocurrencia en el nodo n es de $1/K$. Para el escenario de capacidad ilimitada, C^n es un número aleatorio que está distribuido uniformemente en el intervalo de $[1000, 2000]$, donde se cumple que $x_p^n \ll C_p^n$; para los escenarios con capacidad limitada C^n está distribuida uniformemente en el intervalo de $[5, 10]$, en este caso puede suceder que no se pueda cumplir con la demanda por la capacidad del proceso. Se generó un conjunto de datos con capacidad limitada y otro con capacidad ilimitada, para lograr

comparar los escenarios en igualdad de condiciones, se generaron 5020 escenarios aleatorios para los parámetros y variables de decisión (excluyendo las variables de capacidad), que fueron utilizados para ambos conjuntos de datos, seguidamente se agregó la variable de capacidad correspondiente a cada conjunto.

B. Prueba de funciones de activación

Una vez establecidos los conjuntos de datos, se alimenta la red neuronal con los 5020 sets de datos generados aleatoriamente, de los cuales se asigna un 60% para el entrenamiento de la red, 20% para la validación y un 20% para la prueba. Seguidamente se define que los parámetros son datos no conocidos en la realidad, y las variables, tales como cantidad de piezas a procesar y capacidad, son conocidos de antemano. Por esta razón, se plantea elaborar una red neuronal, tanto para capacidad limitada como ilimitada, que permita calcular el valor de la función objetivo a partir de unas variables de entrada conocidas. Con el fin de definir la función de activación que diera un menor porcentaje de error de entrenamiento, se utilizó el software STATISTICA versión 7.0. Se le indicó al programa probar con 100 redes, y todos los tipos de redes neuronales, y que de esas 100 escoja las 5 con menor error de entrenamiento. Los resultados obtenidos se muestran a continuación.

Modelo	Perfil de Red Neuronal	Error de entrenamiento	Error de selección	Error de prueba	Algoritmo de entrenamiento
A	MLP 3:3-16-1:1	0,002871	0,002960	0,002896	BP100, CG20, CG68b
	Linear 6:6-1:1	0,00169	0,0011743	0,001736	PI
	GRNN 7:7-3020-2-1:1	0,001649	0,001721	0,001704	PI
	RBF 6:6-36-1:1	0,000001	0,000001	0,000001	SS
	RBF 6:6-43-1:1	0,000000	0,000000	0,000000	KM,KN,PI
B	MLP 8:8-7-1:1	0,10924	0,11847	0,120173	BP100, CG20, CG68b
	Linear 4:4-1:1	0,108125	0,117377	0,117713	PI
	GRNN 4:4-3020-2-1:1	0,000003	0,000003	0,000003	SS
	RBF 12:12-91-1:1	0,000003	0,000003	0,000003	SS, KN, PI
	RBF 12:12-93-1:1	0,000003	0,000003	0,000003	SS, KN, PI

TABLE II

DESCRIPCIÓN DE LAS RNA OBTENIDAS PARA EL MODELO A Y EL MODELO B

El tabla II muestra las mejores 5 funciones de activación para cada modelo, para seleccionar la mejor función de las 5, se buscó la red que tuviera el menor error de entrenamiento, lo que implica una mejor predicción de los datos, siendo un “RBF

6:6-43-1:1” con 0.000000 de error para el modelo A (sin límite de capacidad) y un “RBF 12:12-93-1:1” con 0,000003 de error de entrenamiento para el modelo B (con límite de capacidad). Ambos modelos cuentan con una red de función de base radial (RBF), lo cual explica que la arquitectura de ambas redes se caracteriza por tener una capa simple de entrada, una capa simple oculta y una simple de salida [25].

Por otra parte, se observa que el algoritmo de aprendizaje que utilizaron las redes RBF seleccionadas en ambos casos, fue una combinación óptima e integrada de KM (algoritmo de entrenamiento de neuronas de base radial), KN (vecinos K más cercanos, algoritmo de determinación de radio de desviación), PI (pseudoinversión, optimización lineal de los errores menores cuadrados) y SS (algoritmos de entrenamiento de submuestras) [25].

Se identifica que el modelo A determina que de las 13 variables de entrada con las que se alimentó la red, únicamente tienen un efecto significativo sobre el costo total de producción, 6 variables, y trabajó con 43 neuronas en la capa oculta de la red, y la neurona de salida representa el costo total de producción, tal como lo muestra la figura 1.

Las 6 variables que prioriza el modelo A son: cantidad de ventas perdidas por remanufacturar productos, cantidad de partes procesadas y variable de configuración del proceso, donde se puede inferir que el modelo al contemplar una capacidad ilimitada, las variables de máxima capacidad de desmontaje, máxima capacidad de reacondicionamiento y máxima capacidad de reensamblaje, así como la cantidad de inventario, no tienen un efecto significativo sobre el costo total de producción, dado que para este caso, la capacidad posee un valor tal que $x_p^n \ll C_p^n$.

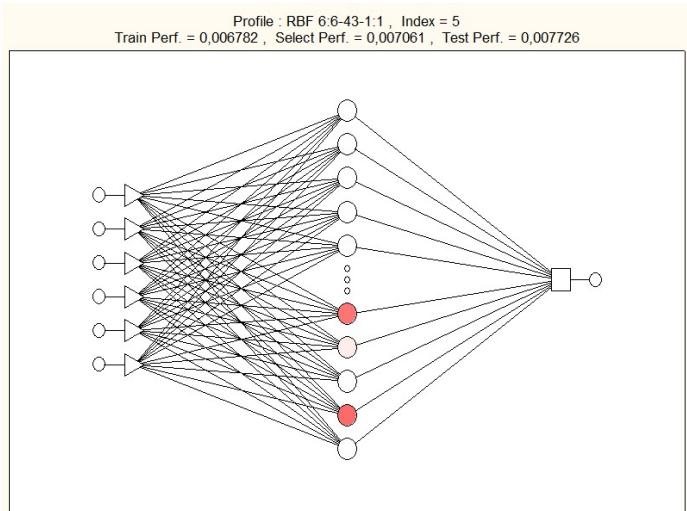


Fig. 1. Red Neuronal para el modelo A (sin límite de capacidad)

Sin embargo, el modelo B toma en cuenta 12 de las 13 variables de entrada para realizar las predicciones, al ser este el modelo que tiene una capacidad con límite, las variables de máxima capacidad de desmontaje, máxima capacidad de reacondicionamiento, máxima capacidad de reensamblaje y cantidad de inventario sí tienen un efecto significativo sobre la variable de respuesta, que es el costo total de producción.

Además de las 12 variables de entrada, este modelo cuenta con 93 neuronas ocultas y 1 neurona de salida, que es el costo total de producción. La red descrita se muestra en la figura 2.

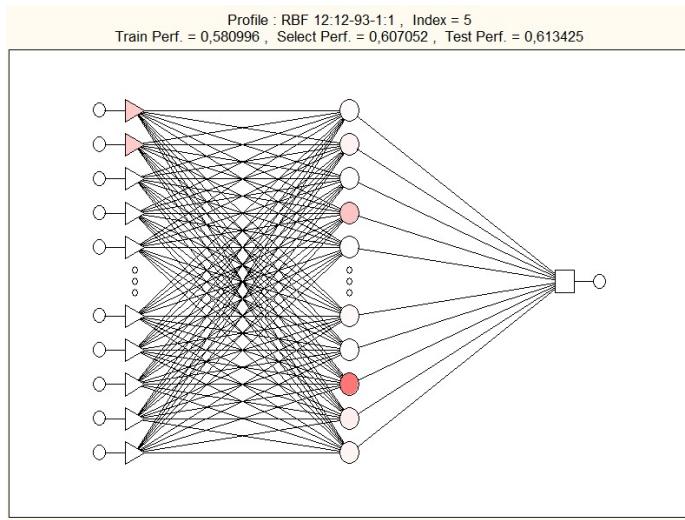


Fig. 2. Red Neuronal para el modelo B (con límite de capacidad)

Seguidamente, se realiza una prueba de “caso definido por el usuario”, en el cual se busca validar el bajo error de predicción para ambos modelos, por lo que dicha evaluación consiste en probar valores aleatorios en 5 instancias generadas con el modelo estocástico de dimensionamiento de lotes, mencionadas anteriormente, para alimentar las redes. Se observa que el modelo A tiene un error promedio de predicción de 0.35%, lo cual indica que la red neuronal tuvo un 99.65% de precisión para predecir cuál será el costo total de producción con las 6 variables de entrada para el escenario sin límite de capacidad. Por otra parte, para el modelo B se obtiene un error promedio de predicción de 5.58%, lo cual indica que la precisión de su red neuronal fue de 94.42% para predecir el costo total de producción. La fuente de error del 5.58% se puede explicar tomando en cuenta que el modelo B trabaja con un rango de valores límite para las 3 variables de capacidad mucho menor que las del primer modelo, por lo que dichos valores extremos pueden disminuir el nivel de precisión de predicción de la red. Dichos resultados de la prueba se muestran en la tabla III.

Modelo	Costo total de producción real	Costo total de producción predicho por la red	Error
A	\$ 328 330	\$ 326 483	0,56 %
	\$ 185 906	\$ 186 173	0 %
	\$ 262 421	\$ 261 940	0,18 %
	\$ 214 722	\$ 212 627	0,98 %
	\$ 259 185	\$ 258 776	0,16 %
	Error promedio de modelo A		0,35 %
B	\$ 324 487	\$ 300 327	5,33 %
	\$ 171 500	\$ 184 396	7,52 %
	\$ 301 699	\$ 314 286	4,17 %
	\$ 434 506	\$ 463 555	6,69 %
	\$ 154 404	\$ 147 949	4,18 %
	Error promedio de modelo B		5,58 %

TABLE III

EVALUACIÓN DEL ERROR DE PREDICCIÓN DEL MODELO A Y MODELO B

VI. CONCLUSIONES

Para empezar, se logra concluir que por medio de las redes neuronales se logra conocer cuáles variables del modelo de dimensionamiento de lotes afectan de manera significativa el costo total de producir. Es importante destacar que para los modelos de dimensionamiento de lotes es importante considerar la restricción de capacidad limitada que fue agregada, debido a que esta es una variable significativa, y se apega a lo que sucede en la realidad de sistemas de manufactura. A pesar de que el modelo de programación estocástica para problemas de dimensionamiento de lotes de múltiples niveles permite conocer el valor de las variables de entrada que permite optimizar el costo de producción, puede suceder que la empresa no pueda cumplir con dichas variables de entrada. Ante esta situación, la red neuronal permite que a partir de diferentes datos de entrada se pueda predecir los costos asociados a la producción del producto.

VII. FUTURAS LÍNEAS DE INVESTIGACIÓN

Para futuras investigaciones se recomienda investigar la predicción de la red aumentando sus variables de entrada con el fin de apegarse más a la realidad, por ejemplo, considerando productos múltiples o máquinas paralelas.

REFERENCES

- [1] M. Ynzunza Cortés, Carmen Berenice; Izar Landeta, Juan Manuel; Bocarando Chacón, Jacqueline Guadalupe; Aguilar Pereyra, Felipe; Larios Osorio, “El Entorno de la Industria 4.0: Implicaciones y Perspectivas Futuras,” *Conciencia Tecnológica*, p. 54, 2017. [Online]. Available: <http://www.redalyc.org/articulo.oa?id=94454631006>
- [2] G. M. Melega, S. A. de Araujo, and R. Jans, “Classification and literature review of integrated lot-sizing and cutting stock problems,” *European Journal of Operational Research*, vol. 271, no. 1, pp. 1–19, 2018. [Online]. Available: <https://doi.org/10.1016/j.ejor.2018.01.002>
- [3] M. Gruson, J. F. Cordeau, and R. Jans, “The impact of service level constraints in deterministic lot sizing with backlogging,” *Omega (United Kingdom)*, vol. 79, pp. 91–103, 2018. [Online]. Available: <https://doi.org/10.1016/j.omega.2017.08.003>
- [4] F. Hnaini and H. M. Afsar, “Robust single-item lot-sizing problems with discrete-scenario lead time,” *International Journal of Production Economics*, vol. 185, no. February 2016, pp. 223–229, 2017. [Online]. Available: <http://dx.doi.org/10.1016/j.ijpe.2017.01.008>
- [5] I. Slama, O. Ben-Ammar, F. Masmoudi, and A. Dolgui, “Scenario-based stochastic linear programming model for multi-period disassembly lot-sizing problems under random lead time,” *IFAC-PapersOnLine*, vol. 52, no. 13, pp. 595–600, 2019. [Online]. Available: <https://doi.org/10.1016/j.ifacol.2019.11.224>
- [6] V. Azizi, G. Hu, and M. Mokari, “A two-stage stochastic programming model for multi-period reverse logistics network design with lot-sizing,” *Computers and Industrial Engineering*, vol. 143, no. September 2019, p. 106397, 2020. [Online]. Available: <https://doi.org/10.1016/j.cie.2020.106397>
- [7] Y. Li and G. Hu, “Shop floor lot-sizing and scheduling with a two-stage stochastic programming model considering uncertain demand and workforce efficiency,” *Computers and Industrial Engineering*, vol. 111, pp. 263–271, 2017. [Online]. Available: <http://dx.doi.org/10.1016/j.cie.2017.07.014>
- [8] T. Wu, F. Xiao, C. Zhang, Y. He, and Z. Liang, “The green capacitated multi-item lot sizing problem with parallel machines,” *Computers and Operations Research*, vol. 98, pp. 149–164, 2018. [Online]. Available: <https://doi.org/10.1016/j.cor.2018.05.024>
- [9] G. Zhang, J. Shi, S. S. Chaudhry, and X. Li, “Multi-period multi-product acquisition planning with uncertain demands and supplier quantity discounts,” *Transportation Research Part E: Logistics and Transportation Review*, vol. 132, no. October, pp. 117–140, 2019. [Online]. Available: <https://doi.org/10.1016/j.tre.2019.11.005>

- [10] Z. Hu and G. Hu, "A multi-stage stochastic programming for lot-sizing and scheduling under demand uncertainty," *Computers and Industrial Engineering*, vol. 119, no. February, pp. 157–166, 2018. [Online]. Available: <https://doi.org/10.1016/j.cie.2018.03.033>
- [11] O. A. Kılıç and H. Tunc, "Heuristics for the stochastic economic lot sizing problem with remanufacturing under backordering costs," *European Journal of Operational Research*, vol. 276, no. 3, pp. 880–892, 2019. [Online]. Available: <https://doi.org/10.1016/j.ejor.2019.01.051>
- [12] P. B. Macedo, D. Alem, M. Santos, M. L. Junior, and A. Moreno, "Hybrid manufacturing and remanufacturing lot-sizing problem with stochastic demand, return, and setup costs," *International Journal of Advanced Manufacturing Technology*, vol. 82, no. 5-8, pp. 1241–1257, 2016.
- [13] F. Quezada, C. Gicquel, and S. Kedad-Sidhoum, "Stochastic dual dynamic integer programming for a multi-echelon lot-sizing problem with remanufacturing and lost sales," *2019 6th International Conference on Control, Decision and Information Technologies, CodIT 2019*, pp. 1254–1259, 2019.
- [14] H. G. Gören and S. Tunali, "Solving the capacitated lot sizing problem with setup carryover using a new sequential hybrid approach," *Applied Intelligence*, vol. 42, no. 4, pp. 805–816, 2015.
- [15] L. Li, S. Song, and C. Wu, "Solving a Multi-Level Capacitated Lot Sizing Problem with Random Demand via a Fix-and-Optimize heuristic," *2015 IEEE Congress on Evolutionary Computation, CEC 2015 - Proceedings*, no. Liuxi Li, pp. 2721–2728, 2015.
- [16] P. Piñeyro and O. Viera, "The economic lot-sizing problem with remanufacturing: analysis and an improved algorithm," *Journal of Remanufacturing*, vol. 5, no. 1, 2015. [Online]. Available: <http://dx.doi.org/10.1186/s13243-015-0021-8>
- [17] S. Chotayakul and V. Punyangarm, "An MIP-based heuristic approach to determine production lot size for capacitated single-stage production processes with stochastic demand on parallel machines," *2017 6th International Conference on Industrial Technology and Management, ICITM 2017*, pp. 69–74, 2017.
- [18] J. de Armas and M. Laguna, "Parallel machine, capacitated lot-sizing and scheduling for the pipe-insulation industry," *International Journal of Production Research*, vol. 58, no. 3, pp. 800–817, 2020. [Online]. Available: <https://doi.org/00207543.2019.1600763>
- [19] H. Tempelmeier and T. Hilger, "Linear programming models for a stochastic dynamic capacitated lot sizing problem," *Computers and Operations Research*, vol. 59, pp. 119–125, 2015. [Online]. Available: <http://dx.doi.org/10.1016/j.cor.2015.01.007>
- [20] M. Hrouga, M. Godichaud, and L. Amodeo, "Efficient metaheuristic for multi-product disassembly lot sizing problem with lost sales," *IEEE International Conference on Industrial Engineering and Engineering Management*, vol. 2016-December, pp. 740–744, 2016.
- [21] J. Á. Martínez, "Aprendizaje supervisado en conjuntos de datos no balanceados con Redes Neuronales Artificiales. Métodos de mejora de rendimiento para modelos de clasificación binaria en diagnóstico médico," p. 137, 2017. [Online]. Available: <http://openaccess.uoc.edu/webapps/o2/bitstream/10609/64768/3/jaguilamaTFM0617memoria.pdf>
- [22] N. A. Ann, A. Juan, and T. Lucas, "Facultat de Matemàtiques i Informàtica Universitat de Barcelona Machine Learning : Modelos Ocultos de Markov (HMM) y Redes Director ;," 2017.
- [23] N. Nadai, A. H. Melani, G. F. Souza, and S. I. Nabeta, "Equipment failure prediction based on neural network analysis incorporating maintainers inspection findings," *Proceedings - Annual Reliability and Maintainability Symposium*, 2017.
- [24] B. Defourny, "Machine Learning Solution Methods for Multistage Stochastic Programming," p. 200, 2010. [Online]. Available: http://www.princeton.edu/\~defourny/PhDthesis__B__Defourny.pdf
- [25] P. Sakiewicz, K. Piotrowski, J. Ober, and J. Karwot, "Innovative artificial neural network approach for integrated biogas – wastewater treatment system modelling: Effect of plant operating parameters on process intensification," *Renewable and Sustainable Energy Reviews*, vol. 124, p. 109784, 2020. [Online]. Available: <https://doi.org/10.1016/j.rser.2020.109784>



Alejandro Castro Estudiante de quinto año de la carrera de Licenciatura en Ingeniería Industrial de la Universidad de Costa Rica. Es egresado del Colegio Bilingüe Nueva Esperanza, Heredia. Dentro de sus áreas de interés profesional se encuentran: Logística, Producción y Calidad . Correo electrónico: alejandro.castroperez@ucr.ac.cr



María Paula Huezo Estudiante de quinto año de la carrera Ingeniería Industrial en la Universidad de Costa Rica. Es egresada del Liceo Laboratorio Emma Gamboa. Dentro de sus áreas de interés profesional se encuentran Logística de la cadena de suministro, sistemas automatizados de manufactura y administración de operaciones. Correo electrónico: maria.huezo@ucr.ac.cr



Luis Madrigal Estudiante de cuarto año de la carrera de Licenciatura en Ingeniería Industrial en la Universidad de Costa Rica. Es egresado del Colegio Nuestra Señora del Pilar. Dentro de sus áreas de interés profesional se encuentran: Robótica, logística y operaciones. Correo electrónico: luis.madrigalfernandez@ucr.ac.cr



Ricardo Marín Estudiante de quinto año de la carrera de Licenciatura en Ingeniería Industrial de la Universidad de Costa Rica. Es egresado del Colegio Claretiano, Heredia. Dentro de sus áreas de interés profesional se encuentran: Calidad, Producción y Robótica. Correo electrónico: ricardo.marin@ucr.ac.cr



Alejandra Urtecho Estudiante de quinto año de la carrera de Licenciatura en Ingeniería Industrial de la Universidad de Costa Rica. Es egresada del Liceo Experimental Bilingüe de San Ramón. Entre sus áreas de interés en el ámbito profesional se encuentran gestión de proyectos y procesos de negocio. Correo electrónico: maria.urtecho@ucr.ac.cr